Bases de Dados

MIEIC | BDAD 2017/2018 | José Devezas

Conteúdos de apoio

Os conteúdos aqui apresentados servem informalmente de suporte aos conteúdos lecionados nas aulas teóricas, tentando-se uma abordagem mais coloquial e menos formal (onde possível), de forma a fomentar a aprendizagem durante as aulas teórico-práticas (TP).

O que precisam de saber?

- Modelo Conceptual
- · Esquema Relacional
- · Modelo Relacional
 - Dependências funcionais
 - Formas normais
 - 1^a Forma Normal (1NF)
 - 2^a Forma Normal (2NF)
 - 3^a Forma Normal (3NF)
 - Forma Normal Boyce-Codd
 - Forma minimal
 - Fecho de um conjunto de atributos
 - Teste da caça
 - Chaves
 - Super-chave
 - Chave-candidata
 - Chave primária
 - Chave alternativa
- Linguagem de Definição de Dados (SQL)
- Álgebra Relacional
- Linguagem de Manipulação de Dados (SQL)
- NoSQL (MongoDB)

Projeto

Datas Importantes (2017/2018)



- 25 Fevereiro => Definição de grupo e submissão do tema
- 11 Março => Entrega 1
- 15 Abril => Entrega 2
- 27 Maio => Entrega 3

Visão Geral

- Grupos de 3 alunos
- Devem propor tema ao docente das teórico-práticas via Moodle, enviando uma descrição detalhada (máx. 100 palavras), similar aos enunciados das aulas TP.
- Trabalho similar ao dos guiões, a entregar em 3 fases:
 - Entrega 1:
 - A. Definição do Modelo Conceptual
 - Entrega 2:
 - B. Definição do Esquema Relacional
 - C. Análise de Dependências Funcionais e Formas Normais
 - D. Criação da base de dados em SQLite
 - E. Adição de restrições à base de dados
 - F. Carregamento de dados
 - Entrega 3:
 - G. Interrogação da Base de dados
 - H. Adição de gatilhos à base de dados

Consulta Recomendada

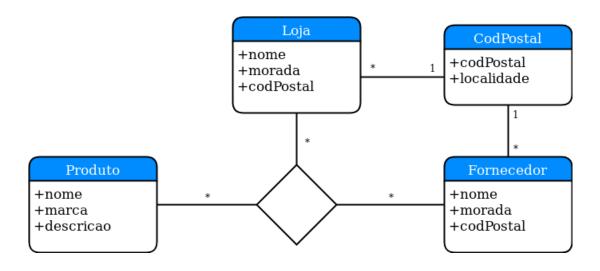
Hector Garcia-Molina, Jeffrey D. Ullman, Jennifer Widom: Database Systems - The Complete Book (2nd Edition). Pearson Education 2009, ISBN 978-0-13-187325-4, pp. I-XXVI, 1-1203

Aula 1

Modelo Conceptual

Esta é uma representação mais próxima dos requisitos do negócio e mais desligada da implementação e das necessidades de desenho do esquema da base de dados.

Exemplo de um Modelo Conceptual simples para gestão de produtos e fornecedores de uma loja:



Esquema Relacional

Chaves primárias identificadas com sublinhado e chaves estrangeiras identificadas com seta para relação (i.e., tabela) respetiva:

```
CodPostal(codPostal, localidade)

Loja(idLoja, nome, morada, codPostal -> CodPostal)

Produto(idProduto, nome, marca, descricao)

Fornecedor(idFornecedor, nome, morada, codPostal -> CodPostal)

LojaProdutoFornecedor(idLoja -> Loja, idProduto -> Produto, id
Fornecedor -> Fornecedor)
```

Aula 2

Modelo Conceptual vs Modelo Relacional

Diferentes propósitos:

https://www.visual-

paradigm.com/support/documents/vpuserguide/3563/3564/85378 conceptual,l.html

- Modelo Conceptual: mais próximo dos requisitos do negócio.
- Modelo Relacional: modelo físico, traduzido do modelo conceptual, de forma a representar diretamente a estrutura da base de dados.

Modelo Relacional

https://en.wikipedia.org/wiki/Relational_model

Esta é uma representação utilizada para o desenho do esquema da base de dados e é geralmente obtida com o suporte do Modelo Conceptual.

Dependências funcionais

A dependência funcional é funcional no sentido em que um determinado conjunto de atributos $\{A_1,A_2,A_3\}$ implica outro conjunto de atributos $\{B_1,B_2\}$, tal que determinada combinação de valores em $\{A_1,A_2,A_3\}$ apenas gera uma combinação de valores em $\{B_1,B_2\}$. Vários registos podem ser recuperados com base em $\{A_1,A_2,A_3\}$, mas os valores de B_1 e B_2 são sempre iguais, se a dependência funcional $A_1,A_2,A_3\to B_1,B_2$ se verificar.

É como numa função matemática. Por exemplo:

- Se f(x) = 2x, então:
 - f(2) = 4
 - $\circ f(-2) = 4$
- Mas f(2) apenas tem um valor, que é 4.
- Não pode ter mais do que um valor!

Nós definimos as dependência funcionais com base nos requisitos apresentados, geralmente a partir de uma relação que representa uma tabela (ou várias, depois da normalização) numa base de dados, como o conjunto de todos os atributos que aí queremos armazenar. Por exemplo, vamos tentar definir a relação Loja:

```
Loja(nomeLoja, moradaLoja, codPostalLoja,
nomeProduto, marcaProduto, descricaoProduto,
nomeFornecedor, moradaFornecedor, codPostalFornecedor)
```

Ou, de forma mais sucinta:

```
Loja(NL, ML, CPL, NP, MP, DP, NF, MF, CPF)
```

Alguns exemplos de dependências funcionais (requisitos em monospace):

```
D=\{ Podem existir várias lojas com o mesmo nome, mas apenas uma por código postal. NL,CPL	o ML, Um produto pode ser fabricado por várias marcas, mas cada produto tem a sua descrição por marca. NP,MP	o DP, Qualquer produto de determinada marca é sempre fornecido pelo mesmo fornecedor. MP	o NF, Mas o mesmo fornecedor pode distribuir diferentes produtos da mesma marca a partir de diferentes localizações. NP,MP	o NF,CPF .... \}
```

Formas normais

http://www.bkent.net/Doc/simple5.htm http://www2.york.psu.edu/~lxn/IST_210/normal_form_definitions.html

Tal como o nome indica, as formas normais ajudam-nos a normalizar as nossas relações, no sentido de garantir propriedades como a atomicidade ou de evitar redundância, minimizando assim o custo de armazenamento e facilitando a atualização de valores.

1a Forma Normal (1NF):

https://en.wikipedia.org/wiki/First_normal_form

- Foco na atomicidade (i.e., indivisibilidade)
- Regras
 - Eliminar grupos repetidos em tabelas individuais
 - Exemplos de grupos repetidos:
 - Coluna Telefone, com o valor 555-222-000, 555-333-111;
 - Duas colunas Telefone1 e Telefone2.
 - o Criar uma tabela separada para cada conjunto de dados relacionados.
 - Exemplo: dados sobre uma Lojas e dados sobre Fornecedor es devem estar separados.

- o Identificar cada conjunto de dados relacionados com uma chave primária.
 - Qualquer chave-candidata pode ser chave-primária, mas apenas pode existir uma chave-primária, enquanto podem existir várias chaves-candidatas (UNIQUE em SQL).

2ª Forma Normal (2NF):

https://en.wikipedia.org/wiki/Second_normal_form

Second normal form is violated when a non-key field is a fact about a subset of a key.

- -- http://www.bkent.net/Doc/simple5.htm
- Foco na relação entre atributos chave e atributos não-chave.
- Regras
 - Deve estar na 1^a Forma Normal.
 - Todos os atributos não-chave devem ser diretamente dependentes dos atributos chave no seu todo.
 - Ou seja, atributos não-chave não podem ser dependentes de partes das chaves.

3ª Forma Normal (3NF):

https://en.wikipedia.org/wiki/Third_normal_form http://rdbms.opengrass.net/2_Database%20Design/2.2_Normalisation/2.2.6_3NF-Transitive%20Dependency.html

Third normal form is violated when a non-key field is a fact about another non-key

-- http://www.bkent.net/Doc/simple5.htm

The key, the whole key, and nothing but the key, so help me Codd. 🙏



- -- http://www.itprotoday.com/microsoft-sql-server/so-help-me-codd
- Foco na relação de transitividade entre atributos chave e atributos não-chave.
- Geralmente considera-se uma base de dados "normalizada" quanto está na 3ª Forma Normal.
- Regras
 - Deve estar na 2^a Forma Normal.
 - Não devem existir dependências transitivas entre atributos não-chave e atributos chave.

Forma Normal Boyce-Codd (BCNF; 3.5NF):

https://en.wikipedia.org/wiki/Boyce%E2%80%93Codd_normal_form

• 3ª Forma Normal on steroids.

- Regra
 - Todos os lados esquerdo das dependências funcionais (não triviais) devem ser super-chaves da relação.
 - Se estiver na 3NF e não houver chaves-candidatas com sobreposição, garantidamente está na BCNF.
 - Mas se houver sobreposição, tanto pode estar como não estar.

Forma minimal

(Minimal basis; The Synthesis Algorithm for 3NF Schemas)

- Regras
 - Todos os lados direitos das dependências funcionais (DFs) têm apenas um atributo.
 - Se alguma dependência funcional for removida, deixamos de ter uma forma minimal.
 - Se removermos algum dos atributos do lado esquerdo, deixamos de ter uma forma minimal.
- A forma minimal ajuda-nos a chegar à 3ª Forma Normal:
 - o Os lados esquerdos das das DFs tornam-se chaves primárias das novas relações;
 - Os respetivos lados direitos por chave primária são incluídos nessa relação;
 - Deve existir pelo menos uma nova relação com uma super-chave da relação original (caso contrário a junção terá perdas).

Chaves

Super-chave:

https://en.wikipedia.org/wiki/Superkey https://dba.stackexchange.com/a/71926

- "Superconjunto de uma chave", ou seja, chave que contém as chaves minimais.
- Identifica de forma única os registos, mas não é minimal!
- Por exemplo: se os registos numa relação podem ser unicamente identificados pelos atributos A_1 , A_2 e A_3 , então $\{A_1,A_2,A_3,A_7\}$ é uma super-chave dessa relação. Mas se retirarmos A_7 já passa a ser uma chave-candidata, porque é minimal.

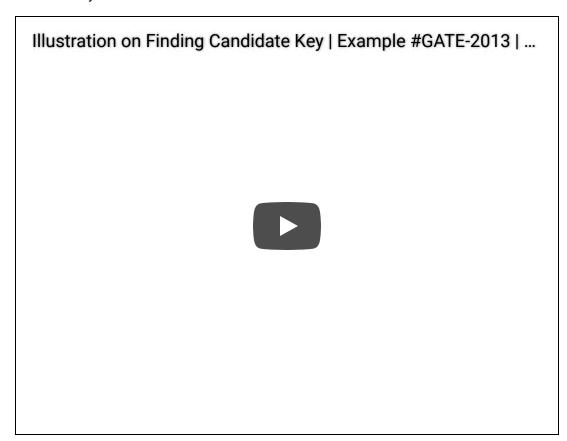
Chave-candidata:

https://en.wikipedia.org/wiki/Candidate_key

- Uma chave-candidata (ou simplesmente chave, no livro recomendado) é uma superchave minimal.
- Ou seja, não inclui atributos redundantes para identificar de forma única os registos.
- Para encontrar todas as chaves-candidatas:
 - Com base nas dependências funcionais, criar o conjunto de atributos que não aparecem no lado direito das DFs.

- Calcular o fecho desse conjunto e verificar se contém todos os atributos.
 - Se sim, então é uma chave-candidata.
 - Se não, estender o conjunto de atributos com combinações de outros atributos

Este vídeo ajuda:



https://youtu.be/9fuJUQJd-A8

Chave-primária:

https://en.wikipedia.org/wiki/Primary_key

- Corresponde à escolha de uma chave-candidata.
- Todas as outras chaves-candidatas passam a ser chaves-alternativas.

Chave-alternativa:

https://en.wikipedia.org/wiki/Primary_key#Alternate_key

• Qualquer chave-candidata que não foi escolhida para ser chave-primária.

Fecho de um conjunto de atributos

(Closure of a set of attributes)

• Fecho do conjunto X é representado por X^+ .

- Para calcular o fecho de um conjunto de atributos {J, T, Y}, começamos por incluir os atributos originais e expandir os vários subconjuntos com base nas dependências funcionais.
 - \circ Por exemplo, se tivermos as dependências $D = \{JT \to A, J \to D, T \to AY\}$,
 - Vamos expandir $\{J\}$, $\{T\}$, $\{Y\}$, $\{J,T\}$, $\{J,Y\}$, $\{T,Y\}$ e $\{J,T,Y\}$
 - Resultando em (passo-a-passo):
 - {*J*,*D*}
 - Expandir $\{J\}$ resulta em $\{J,D\}$ (inclui o próprio J e, com base em $J \to D$, adicionamos o D).
 - $\{J, D, T, A, Y\}$
 - Não existe dependência funcional a partir de $\{J,D\}$, por isso vamos expandir $\{T\}$, incluindo o próprio T e, com base em $T \to AY$, incluímos A e Y.
 - ${J,T,Y}^+ = {J,D,T,A,Y}$
 - Já não podemos fazer mais nenhuma expansão, por isso chegamos ao fecho $\{J, D, T, A, Y\}$ do conjunto $\{J, T, Y\}$.

Teste da caça

(Chase test for lossless join)

https://en.wikipedia.org/wiki/Chase_(algorithm)

- Algoritmo (tradução para humano):
 - a. Criar um quadro com todos os atributos como colunas, em maiúsculas (p.e., A,B,C).
 - b. Dada uma decomposição de uma relação R em várias relações R_1, R_2, \ldots, R_n , preencher uma linha do quadro por relação, colocando:
 - i. Em minúsculas (p.e., a, b, c) todos os atributos que fazem parte da relação.
 - ii. E em minúsculas com o índice da linha (p.e., a_1,b_1,c_1) todos os atributos que não fazem parte da relação.
 - c. Numa passagem pelo quadro, resolver, linha a linha, as dependências funcionais, removendo o índice para os atributos que podem ser resolvidos através dos atributos sem índice.
 - d. Se encontrarmos uma linha sem índices, então podemos garantir a junção sem perdas, caso contrário não.

Aulas 3 e 4

Linguagem de Definição de Dados (SQL)

SQL, de Structured Query Language, é uma linguagem que tanto permite definir as estruturas de dados como manipular os dados nelas armazenados. Vamos olhar para definição de dados em SQL, demonstrando com um workflow típico, para a criação de um esquema em SQLite:

Apagar tabelas, se existirem

Garante que não vamos ter erros no passo seguinte de criação das tabelas.

```
DROP TABLE IF EXISTS tabela;
```

Criar uma tabela

Definição do nome da tabela, conjunto de atributos e seus tipos e restrições.

```
CREATE TABLE tabela (
attr1 TEXT NOT NULL,
attr2 TEXT REFERENCES outra_tabela(attr_pk_o_tabela),
attr3 NUMBER CHECK (attr3 > 0),
email TEXT,
CONSTRAINT attr1_pk PRIMARY KEY (attr1),
CONSTRAINT ch_attr1_attr2 CHECK (attr1 <> attr2)

);
```

Como experimentar

Devem instalar o sqlite3. Podem utilizar a linha de comandos para carregar ficheiros *.sql, quer com o esquema da base de dados (DDL), quer com interrogações (DML).

Se quiserem algo mais visual, existem várias ferramentas integradas nos IDEs do costume (p.e., o Database Navigator nos produtos da JetBrains, como o IntelliJ ou o PyCharm). Podem ainda experimentar o DB Browser for SQLite, compatível com Windows, Mac e Linux (comando sqlitebrowser).

Aula 5

Álgebra Relacional

https://en.wikipedia.org/wiki/Relational_algebra

(Pensar nisto como uma versão matemática do SQL, para interrogação à BD)

O SQL tanto pode servir para a definição de dados (os esquemas que definem as tabelas, suas chaves e restrições, bem como vistas e gatilhos), como para a manipulação de dados (inserções, remoções, atualizações ou interrogações).

Antes de olharmos para o SQL como linguagem de manipulação de dados, vamos primeiro aprender sobre a notação matemática (álgebra relacional) que estabelece as bases teóricas para a interrogação das bases de dados (o nosso SELECT em matemática).

Vamos definir alguns operadores unários e binários aplicáveis a relações e que resultam em conjuntos. Se temos conjuntos, então podemos também usar os operadores de teoria de conjuntos. Por exemplo:

- União: []
- Interseção: ⋂
- Produto cartesiano: ×
- Diferença: ou \

Operadores unários

Projeção: $\Pi_{a_1,\ldots,a_n}(R)$

Filtragem de atributos a_1, \ldots, a_n numa relação R (colunas da tabela).

Projeção => Pi

Seleção: $\sigma_{arphi}(R)$

Filtragem de tuplos com base na condição φ numa relação R (linhas da tabela; os registos).

Seleção => Sigma

Renomeação: $ho_{a/b}(R)$

Alteração do nome do atributo b para a, em todos os tuplos.

Renomeação => Rho

Operadores binários

Junção natural: $R\bowtie S$

Junta R e S com base em todos os atributos em comum.

heta-junção: $Roxedom_{a\, heta\,b}^{oxtimes}S$

Filtra o produto cartesiano $R \times S$ pela condição $a \theta b$. Quando θ é o operador de igualdade (=), então temos uma equijunção.

Semijunção esquerda: $R \ltimes S$

Filtra todos os tuplos de R com base na junção com S, mas não inclui atributos de S no resultado.

Semijunção direita: R
times S

Filtra todos os tuplos de S com base na junção com R, mas não inclui atributos de R no resultado.

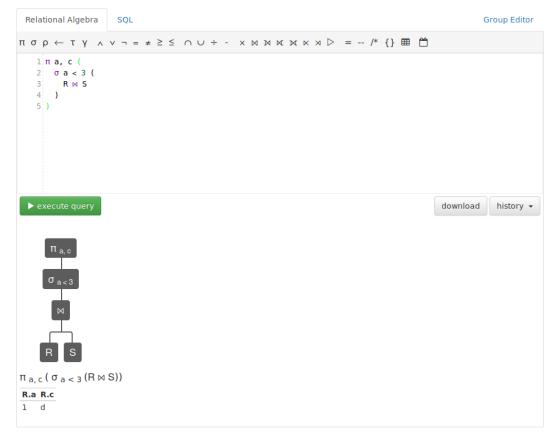
Anti junção: $R \triangleright S$

Filtra todos os tuplos de R com base na junção com S, incluindo apenas todos os tuplos que não fazem parte da junção.

Divisão: $R \div S$

Na divisão, fazemos a junção com S, mantendo os atributos únicos de R e removendo tuplos duplicados. Mais detalhes em: http://users.abo.fi/soini/divisionEnglish.pdf

Podem experimentar usar o RelaX, uma ferramenta online para aprenderem mais sobre álgebra relacional, testando as vossas interrogações e visualizando as equivalências em SQL. O RelaX foi criado pelo Johannes Kessler, da Universidade de Innsbruck, na Áustria.



Tables from and for the lecture Databases: Foundations, Data Models and System Concepts - University of Innsbruck chapter 3

Aula 6

Linguagem de Manipulação de Dados (SQL)

Inserir dados numa tabela

Geralmente feito a partir de um programa.

```
INSERT INTO tabela VALUES ('567', '23', 987, 'jld@fe.up.pt');
```

Notar que, durante esta inserção, deve existir um registo em outra_tabela com chave-primária attr_pk_outra_tabela com valor '23'.

Apagar registos

```
DELETE FROM tabela;
```

Ou, com uma condição:

```
DELETE FROM tabela WHERE attr1 = '567';
```

```
UPDATE tabela SET attr3 = 988 WHERE attr1 = '567';
```

Aula 7

Gatilhos (SQL / SQLite)

Exemplo de um gatilho em SQLite para validação de e-mails

Adaptado de http://www.sqlitetutorial.net/sqlite-trigger/

```
CREATE TRIGGER validar_email_tabela BEFORE INSERT ON tabela

BEGIN

SELECT

CASE

WHEN NEW.email NOT LIKE '%_@__%.__%'

THEN RAISE (ABORT, 'E-mail inválido!')

END;

END;
```

Informação adicional relevante na documentação do SQLite:

- <u>Criar gatilhos:</u> https://www.sqlite.org/lang_createtrigger.html
 - Um gatilho permite definir uma ação que ocorre antes (BEFORE), depois (AFTER) ou em substituição (INSTEAD OF) de um DELETE, INSERT ou UPDATE.
- Criar vistas: https://www.sqlite.org/lang_createview.html
 - Uma vista permite guardar interrogações frequentes à base de dados que geralmente envolvem a junção de várias tabelas ou a aplicação de uma condição (ver Aula 6).
 - As vistas podem por vezes ser otimizadas (vistas materializadas), embora o SQLite n\u00e3o suporte esta funcionalidade.

Aula 8

NoSQL (MongoDB)

Existem várias bases de dados NoSQL:

• Chave-valor (p.e., Berkeley DB);

- Grafos (p.e., Neo4j);
- Documentos (p.e., MongoDB);
- Multi-modelo (p.e., OrientDB, que vê o NoSQL como "Not only SQL" e oferece armazenamento de documentos, grafos, dados relacionais, com esquema, parcialmente com esquema ou sem esquema).

MongoDB é uma das bases de dados NoSQL mais utilizada (e robusta). Assim, vamos utilizá-la como exemplo na aprendizagem do NoSQL.

Características do MongoDB:

- Permite armazenar documentos em JSON;
- Dados não normalizados:
 - Por exemplo, se tivermos documentos de texto com titulo, conteudo e tags, as tags são geralmente armazenadas no próprio documento como um array (p.e., ["databases", "nosql", "lecture"]); se quisermos alterar globalmente o nome de uma tag na base de dados, teremos de o fazer individualmente para cada instância da tag nos vários documentos onde ocorre;
- Esta desnormalização, permite armazenar os documentos conforme estes são frequentemente acedidos, tornando as leituras mais eficientes.
- Em particular no MongoDB e para aplicações web, é útil que estes conteúdos já estejam em formato JSON, evitando assim o overhead do processo de desserialização e contribuindo novamente para um maior eficiência.

Selecionar documentos segundo uma condição e projetar o resultado:

```
db.colecao.find({ campo: "valor" }, { _id: 0, campo: 0 })
```

A base de dados ativa é sempre identificada por db, contendo várias coleções de documentos (p.e., colecao no exemplo). O primeiro parâmetro do find() recebe a nossa condição e o segundo parâmetro determina a projeção, permitindo decidir quais os campos a incluir (0 exclui e 1 inclui, com alguns *defaults* diferentes, mas intituivos, dependendo das combinações usadas).

Contar documentos segundo uma condição:

```
db.colecao.count({ campo: "valor" })
```

Atualizar valores num conjunto de documentos:

```
db.colecao.update({ campo: "valor" }, { $set: { outroCampo: 10 } 
, aindaOutroCampo: true } })
```

Se não tivéssemos usado o operador \$set, o segundo parâmetro iria substituir por completo o documento.

Remover documentos:

```
db.colecao.remove({ campo: "valor" })
```

Exemplo de uma interrogação (real) mais interessante:

Esta interrogação utiliza o aggregate() para aplicar uma série de operações à coleção extra_round_feedback ao estilo pipeline (i.e., é um array de instruções \$unwind, \$group e \$project.

```
db.extra_round_feedback.aggregate([
     {
        /***
        * Desdobra doclist, devolvendo um documento
        * para cada elemento desse array.
        */
       $unwind: "$doclist"
     },
     {
       /***
         * Conta os clicados e não clicados, separadamente,
         * por run e equipa, para cada entrada de feedback.
        */
13
       $group: {
         _id: {
            runid: "$runid",
           _id: "$_id",
            team: "$doclist.team",
            clicked: "$doclist.clicked"
         },
         count: { $sum: 1 }
       }
     },
     /***
      * Transforma as contagens anteriores num array de objetos
      * "stats" com chave "participant" ou "site" e valor igual
      * às respetivas contagens.
```

```
*/
     {
29
        $group: {
         _id: { runid: "$_id.runid", _id: "$_id._id" },
          stats: {
            $push: {
              $cond: {
                if: {
                  $and: [
                    { $eq: [ "$_id.team", "participant" ] },
                    { $eq: [ "$_id.clicked", true ] }
                  ]
                },
40
                then: {
41
                  "participant": "$count"
42
                },
43
                else: {
                  $cond: {
45
                    if: {
46
                      $and: [
47
                        { $eq: [ "$_id.team", "site" ] },
48
                        { $eq: [ "$_id.clicked", true ] }
49
                      ]
                    },
                    then: {
                      "site": "$count"
                    },
                    else: {
                      // Não pode acontecer, por isso foi ignorad
   ο.
                    }
                  }
                }
```

```
}
           }
         }
       }
     },
     /***
      * Determina vitórias, empates e derrotas para a equipa
      * "participant", comparando o número de cliques do
      * "participant" e do "site".
      */
     {
       $project: {
71
         _id: 1,
72
         win: { $gt: [ "$stats.participant", "$stats.site" ] },
         tie: { $eq: [ "$stats.participant", "$stats.site" ] },
74
         loss: { $lt: [ "$stats.participant", "$stats.site" ] }
       }
     },
     /***
      * Agrega o número de vitórias, empates e derrotas por run.
      */
     {
       $group: {
         _id: "$_id.runid",
         wins: { $sum: { $cond: [ "$win", 1, 0 ] } },
         ties: { $sum: { $cond: [ "$tie", 1, 0 ] } },
         losses: { $sum: { $cond: [ "$loss", 1, 0 ] } }
       }
     },
     /***
      * Calcula o "outcome" com base no número de vitórias e
      * derrotas.
```

```
$project: {
           _id: 0,
           runid: "$_id",
           wins: 1,
           ties: 1,
           losses: 1,
           outcome: {
             $cond: [
               {
                 $and: [
                   { $eq: [ "$wins", 0 ] },
104
                   { $eq: [ "$losses", 0 ] }
                 ٦
               },
               0,
                 $divide: [
                   "$wins",
                   { $sum: [ "$wins", "$losses" ] }
                 ]
               }
114
             ]
           }
         }
      }
    ])
```

Observações

Agradeço ao Professor Jorge Sousa Pinto que teve a ideia de utilizar o Dropbox Paper para organizar as aulas e me inspirou a fazer o mesmo.